

장면 서술과 동적 의사결정을 이용한 제로샷 객체 탐색

Zero-Shot Object Navigation Using Semantic Scene Descriptions and Dynamic Decision-Making

조영목¹ · 나세민¹ · 최정준² · 김현진[†]

Yeongmok Cho¹, Semin Na¹, Jeongjun Choi², H. Jin. Kim[†]

Abstract: Zero-shot object navigation is a key Embodied AI task. While recent Vision-Language Model (VLM) methods are promising, they suffer from the text-image modality gap, limiting semantic understanding and persistent false-positive detections. We propose a novel framework to address this limitation. First, our agent uses a VLM to generate rich text descriptions from panoramic observations, using these descriptions as an intermediate representation. This allows relevance matching to occur in a high-density text embedding space, mitigating the modality gap. Second, we introduce an intuitive dynamic decision-making logic. Third, we introduce a robust target verification module that combines VLM-based semantic re-evaluation with a count-based accumulation logic to filter out false positives. Evaluations on the HM3D and MP3D benchmarks show our model achieves superior performance. On HM3D, we reach 55.0 % SR and 33.7 % SPL, notably improving SPL by 3.3 %p over the VLFM baseline. These results validate that our approach effectively mitigates the modality gap and enhances path efficiency through dynamic exploration.

Keywords: Zero-shot object navigation, Embodied AI, Modality gap, Dynamic decision-making

1. 서론

Zero-shot object navigation은 로봇 에이전트가 이전에 경험하지 못한 새로운 환경에서, 별도의 추가 학습 없이 주어진 목표 객체 카테고리(를) 찾아가는 능력을 평가하는 핵심 기술이다. 이를테면, 가정용 로봇이 물건을 가져오거나 리모컨을 찾는 등 인간의 복잡한 명령을 수행하기 위해서는 로봇이 스스로 객체를 찾아가는 능력이 필요하다. 따라서, 이 기술은 로봇이 인간과 같이 의미론적 지식을 활용하여 복잡한 실제 환경을 이해하고 상호작용하는 데 필수적이므로 그 중요성이 크다.

이러한 문제의 접근법은 프론티어 기반 탐색(frontier-based exploration) 방법론^[1]에 기반을 둔다. SemExp^[2]는 이 프론티어 기반 탐색 접근법을 활용하여,

목표 지향적인 의미론적 추론을 결합해 object navigation에 적용한 초기 모델 중 하나이다. 최근에는 별도의 태스크 학습이 필요 없는 VLM (Vision-Language Model) 및 LLM (Large Language Model)을 기반으로 풍부한 의미론적 정보를 활용하는 방법론들이 활발히 연구되고 있다. VLFM^[3]은 VLM을 활용하여 현재의 RGB 관측 이미지와 목표 객체가 포함된 텍스트 프롬프트 간의 유사도를 구하고, 이를 기반으로 value map을 생성하고 최적 프론티어를 선택한다. Hule-nav^[4]은 전방향 관측을 통해 방향성, 객체 등 다양한 의미론적 value map을 구축하여 장기 목표를 선택한다.

하지만, 이처럼 관측 이미지와 목표 텍스트를 VLM의 공동 임베딩 공간(co-embedding space)에서 단순히 매칭하는 방식은 텍스트-이미지 모달리티 갭(text-image modality gap) 문제로 인해 한계가 있음이 보고된 바 있다^[5].

본 연구에서는 이 문제를 해결하기 위한 새로운 프레임워크를 제안한다. 첫째로, 본 프레임워크는 텍스트-이미지 모달리티 갭 문제를 완화하기 위해 텍스트 기반의 중간 표상(intermediate representation)을 활용한다.

※ This work was supported by Samsung Research Funding & Incubation Center of Samsung Electronics under Project Number SRFC-IT2402-17

1. Undergraduate Student, Aerospace Engineering, Seoul National University, Seoul, Korea (zymok@snu.ac.kr, ben020410@snu.ac.kr)

2. PhD Student, Aerospace Engineering, Seoul National University, Seoul, Korea (lojol2327@snu.ac.kr)

† Associate Professor, Corresponding author: Aerospace Engineering, Seoul National University, Seoul, Korea (hjinkim@snu.ac.kr)

VLM을 이용하여 로봇의 파노라마 관측 이미지로부터 목표 객체에 대한 풍부한 맥락이 반영된 장면 서술 (scene description)을 추출한다. 이는 VLM이 모달리티 갭을 극복하고 텍스트 기반의 고밀도 임베딩 공간에서 목표와의 관련성을 더욱 정교하게 판단하도록 돕는다. 둘째로, 효율적인 탐색 직관을 위한 동적 의사결정 로직을 도입한다. 계산 비용이 높은 장면 서술 생성 과정은 탐색 전 과정에 걸쳐 반드시 필요하지는 않으며, 새로운 정보가 필요한 결정적인 순간에만 주위를 두리번거리며 자세히 관찰하는 직관을 반영한다.

나아가, 탐색 성공의 신뢰도를 높이기 위해 목표 검증 모듈을 도입한다. 이는 VLM을 활용한 맥락적 검증과 카운트 기반 누적 검증을 결합한 방식으로, 기존 방식의 고질적인 오탐지 (false positive) 문제를 효과적으로 완화하여 최종 탐색 성공률을 높인다.


본 모델을 Habitat-Matterport 3D (HM3D)^[6]와 Matterport 3D (MP3D)^[7] 데이터셋에서 평가한 결과, 기존 모델 대비 SR (Success Rate)와 SPL (Success weighted by Path Length) 지표에서 우수한 성능 향상을 보였다. 이는 장면 서술을 중간 표상으로 활용하는 방식이 모달리티 갭을 효과적으로 완화하고, 결과적으로 더 효율적이면서 정확한 의미론적 탐색을 가능하게 함을 보여준다.

2. 방법론

Zero-shot object navigation에서 에이전트는 사전에 학습되지 않은 미지의 환경의 임의의 위치에서 탐색을 시작하며, 목표 객체 카테고리가 텍스트로 주어진다. 에이전트는 매 타임 스텝마다 RGB-D 카메라로부터 관측치 O 를 획득한다. 본 연구에서는 [Fig. 1]과 같이 SLAM, 경로점 선택 전략(Waypoint Selection Strategy), 객체 탐지 모듈을 유기적으로 결합한 프레임워크를 제안한다.

2.1. SLAM (Simultaneous Localization and Mapping)

에이전트는 매 스텝 관측치 O 로부터 심도 (depth) 및 주행 기록 (odometry)을 활용하여 에이전트가 관찰한 환경의 2D 지도를 실시간으로 구축하고 지속적으로 갱신한다. 본 프레임워크는 VLFM^[8]을 기반으로 두 가지 주요 지도를 사용한다. Frontier map은 탐색된 영역, 미탐색 영역과 그 사이의 경계인 프론티어를 식별하는 2D 지도이고, value map은 탐색된 영역이 목표 객체를 찾는 데 얼마나 의미론적 연관성이 있는지를 정량화하는 2D 지도다.



[Fig. 1] Overview of the proposed dynamic navigation framework. At each step, the agent sequentially checks for various conditions, and it dynamically selects an action mode. When rotation is required, the 'Looking around' module is activated, generating scene descriptions from panoramic images via a VLM to set a new 'Local Goal'.

2.2. 경로점 선택 전략

본 연구는 VLM의 텍스트-이미지 모달리티 갭으로 인해 발생하는 의미론적 정보의 한계를 극복하고 고비용 추론을 효율적으로 수행하기 위해 여러 모드를 동적으로 선택하는 하이브리드 전략을 채택한다. 에이전트는 매 스텝 [Fig. 1]에 묘사된 바와 같이, 현재 상태를 판단하여 탐색 (Explore), 로컬 목표 이동 (Local Navigate), 회전 및 주변 관찰 (Rotation and Looking around), 목표 이동 (Navigate) 중 하나의 행동 모드를 결정한다.

특히, 본 아키텍처는 고비용 추론을 효율적으로 도입하기 위해 로봇이 능동적으로 주변을 관찰할지 결정한다. 이를 위해, 에이전트는 현재의 value map을 기반으로 다음 경로에 대한 확신이 낮거나, 여러 경로 선택이 가능한 분기점에 도달했다고 판단될 때 회전 모드를 활성화한다. 또한, 불필요한 정보를 방지하기 위해 시간적 제약도 함께 고려된다.

에이전트가 위와 같은 조건을 만족하여 '회전이 필요하다고 판단할 경우, 주변 관찰 (looking around) 모드가 활성화된다. 이 때 에이전트는 360도 회전하며 주변 환경의 파노라마 이미지를 생성한다. 이 파노라마 이미지는 VLM을 통해 처리되어, 목표 객체와 관련된 풍부한 맥락의 장면 서술 (scene description)의 집합, $D(O) = \{d_1, d_2, \dots, d_M\}$ 를 생성한다. 이 서술은 "a white toilet next to the sink"처럼 직접적인 정보나 "a potential bedroom setting"과 같이 목표에 대한 간접적인 단서를 포함한다. 이후, 에이전트는 파노라마 이미지를 생성하기 위해 사용된 N 개의 관측 방향 $\{1, 2, \dots, N\}$ 각각에 대한 관측 이미지 $o_1, o_2, \dots, o_N \in O$ 각각과 장면 서술 $\forall d_j \in D(O)$

를 VLM에 입력한다. VLM은 각 방향의 관측 이미지 o_i 와 장면 서술 d_j 사이의 코사인 유사도 $\Phi(\cdot, \cdot)$ 를 계산하여 관련성 점수를 $C_i = \sum_{j=1}^M \Phi(d_j, o_i)$ 와 같이 결정한다. 최종적으로 가장 높은 점수를 받은 방향 i^* 에 존재하는 프론티어가 새로운 로컬 목표로 설정된다.

$$i^* = \operatorname{argmax}_{i \in \{1, \dots, N\}} C_i = \operatorname{argmax}_{i \in \{1, \dots, N\}} \sum_{j=1}^M \Phi(d_j, o_i) \quad (1)$$

주변 관찰 과정을 통해 로컬 목표가 설정된 경우 에이전트는 로컬 목표 이동 모드로 전환하여 PointNav^[8] 모듈을 통해 해당 지점으로 이동한다.

2.3. 객체 탐지 (Object Detection)

에이전트는 사전 학습된 객체 검출기, YOLOv7^[9]와 Grounding-DINO^[10]를 활용해 매 스텝마다 목표 객체가 시야에 있는지 확인한다. 객체가 발견되면 목표 검증(target verification) 모듈이 활성화된다. 이 모듈은 현재 탐지된 객체가 실제 목표 객체가 맞는지 2차 검증을 수행하여 오탐지를 줄인다. 먼저, 기존의 객체 검출기가 놓치는 의미론적 검증을 추가하기 위해 VLM을 활용한 맥락적 검증 단계를 추가하였다. 또한, 로봇이 임계 거리 이내의 가까운 거리에서 객체를 최초 탐지한 경우 쉽게 오탐지로 귀결되는 문제가 존재하므로, 카운트 기반 누적 검증 방식을 도입하여 동일 객체가 특정 횟수 이상 연속 감지될 때에만 목표로 확정되도록 설계하였다. 최종적으로 목표 객체로 판단될 경우, 검출된 객체는 Mobile-SAM^[11]으로 분할되고 해당 영역의 심도 정보를 결합하여 3D 좌표를 추정한다. 에이전트는 이를 최종 목표 위치로 설정하고 목표 이동 모드로 전환한다.

3. 실험방법

3.1. 데이터셋 및 평가 환경

본 연구의 실험은 3D 환경 시뮬레이터인 Habitat^[12]을 기반으로 수행되었다. 모델의 성능 평가는 실제 3D 스캔 벤치마크 데이터셋인 Habitat-Matterport 3D (HM3D)^[6]와 Matterport 3D (MP3D)^[7]을 사용하였다. HM3D 데이터셋은 20개의 환경에서 6개의 목표 객체 카테고리에 걸쳐 총 2,000개의 에피소드를 포함한다. MP3D 데이터셋은 11개의 환경에서 21개의 목표 객체 카테고리에 대해 총 2,195개의 에피소드를 포함한다.

에피소드의 성공은 에이전트가 제한 시간 (500 스텝) 내에 목표 객체의 1 m 반경 내에서 STOP 액션을 호출

한 경우로 정의된다. 모델의 성능은 SR과 SPL을 사용하였다. SR (Success Rate)은 에이전트가 성공적으로 완료한 에피소드의 총 비율이며, SPL (Success weighted by Path Length)은 에피소드 성공 시 최단 경로 길이를 에이전트의 실제 이동 경로 길이로 나눈 값이다.

3.2. 구현 세부사항

2.2절에서 기술한 주변 관찰 과정에서의 장면 서술 $D(O)$ 생성은 OpenAI API를 통해 GPT-4o 모델을 활용하였다. 또한, 주변 관찰 과정에서 텍스트와 이미지 사이의 유사도 계산 및 2.3절의 목표 검증 모듈로는 BLIP-2^[13]가 활용되었다.

4. 실험결과

[Table 1] Performance comparison on HM3D^[6].

Model	SR (%)	SPL (%)
VLFM ^[3]	52.6	30.4
HuLE-Nav ^[4]	54.1	33.2
Ours (w/o Dynamic Nav)	54.2	28.9
Ours	55.0	33.7

[Table 2] Performance comparison on MP3D^[7].

Model	SR (%)	SPL (%)
VLFM ^[3]	34.8	16.8
Ours (w/o Dynamic Nav)	35.8	15.3
Ours	36.5	17.7

제안 모델의 성능을 검증하기 위해 주요 베이스라인인 VLFM^[3] 및 HuLE-Nav^[4]와 성능을 비교하였다. 또한, 각 제안 모듈의 기여도를 분석하기 위해 2.2절의 경로 점 선택 전략은 제외하고, 2.3절의 목표 검증 로직만 추가한 모델 (Ours (w/o Dynamic Nav))을 포함하여 ablation study를 수행하였다.

[Table 1]은 HM3D^[6] 데이터셋 평가 결과이다. 제안 모델(Ours)은 SR 55.0 %, SPL 33.7 %를 달성하여 HuLE-Nav 대비 SR 0.9 %p, SPL 0.5 %p, VLFM 대비 SR 2.4 %p, SPL 3.3 %p 향상된 성능을 보였다.

[Table 2]의 MP3D^[7] 데이터셋에서도 제안 모델은 SR 36.5 %, SPL 17.7 %를 기록하며, VLFM 대비 SR 1.7 %p, SPL 0.9 %p의 일관된 성능 향상을 확인하였다.

Ablation 분석 결과, Ours (w/o Dynamic Nav) 모델은 VLFM 대비 SR은 향상되었으나 SPL은 감소하였다. 이는 VLM과 카운트 기반의 검증 로직이 오탐지를 줄여

성공률을 높이는 데는 기여하지만, 검증에 소요되는 스텝으로 인해 경로 효율성은 저해할 수 있음을 시사한다. 하지만, 여기에 동적 경로점 선택 전략을 결합한 최종 모델은 SR과 SPL 모두 향상시킴으로써, 두 가지 핵심 전략이 상호 보완적으로 작용하여, 탐색의 정확성과 효율성을 모두 달성하는 데 기여함을 보여준다.

5. 결 론

본 연구는 zero-shot object navigation 태스크에서 VLM의 텍스트-이미지 모달리티 갭 문제를 해결하기 위한 새로운 프레임워크를 제안하였다. 제안하는 프레임워크는 VLM이 생성한 장면 서술을 중간 표상으로 활용하여 모달리티 갭을 완화하고, 탐색과 주변 관찰 모드를 동적으로 전환하는 하이브리드 전략을 통해 탐색 효율성을 높였다. 또한, VLM과 카운트 기반 누적 검증을 활용한 목표 검증 모듈을 도입하여 정확성을 높였다. 제안 모델이 SR과 SPL 지표에서 모두 보인 일관된 성능 향상은 텍스트 중간 표상과 동적 의사결정 로직의 결합이 모달리티 갭을 효과적으로 완화하고, 결과적으로 더 효율적인 탐색 경로를 찾는 데 효과적임을 보여준다.

References

- [1] B. Yamauchi, "A frontier-based approach for autonomous exploration," *Proceedings 1997 IEEE International Symposium on Computational Intelligence in Robotics and Automation CIRA'97. Towards New Computational Principles for Robotics and Automation*, Monterey, CA, USA, pp. 146-151, 1997, DOI: 10.1109/CIRA.1997.613851.
- [2] D. S. Chaplot, D. P. Gandhi, A. Gupta, and R. R. Salakhutdinov, "Object goal navigation using goal-oriented semantic exploration," *34th International Conference on Neural Information Processing Systems*, Vancouver, Canada, vol. 33, pp. 4247-4258, 2020, DOI: 10.48550/arXiv.2007.00643.
- [3] N. Yokoyama, S. Ha, D. Batra, J. Wang and B. Bucher, "VLFM: Vision-Language Frontier Maps for Zero-Shot Semantic Navigation," *2024 IEEE International Conference on Robotics and Automation (ICRA)*, Yokohama, Japan, pp. 42-48, 2024, DOI: 10.1109/ICRA57147.2024.10610712.
- [4] P. Han, M. Zhang, H. Tang, and Y. Zheng, "HuLE-Nav: Human-Like Exploration for Zero-Shot Object Navigation via Vision-Language Models," *NeurIPS 2024 Workshop on Behavioral Machine Learning*, Vancouver, Canada, 2024.
- [5] V. W. Liang, Y. Zhang, Y. Kwon, S. Yeung, and J. Y. Zou, "Mind the gap: Understanding the modality gap in multi-modal contrastive representation learning," *36th International Conference on Neural Information Processing Systems*, New Orleans, United States, vol. 35, pp. 17612-17625, 2022, DOI: 10.48550/arXiv.2203.02053.
- [6] S. K. Ramakrishnan, A. Gokaslan, E. Wijmans, O. Maksymets, A. Clegg, J. M. Turner, E. Undersander, W. Galuba, A. Westbury, A. X. Chang, M. Savva, Y. Zhao, and D. Batra, "Habitat-Matterport 3D Dataset (HM3D): 1000 Large-scale 3D Environments for Embodied AI," *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2021, DOI: 10.48550/arXiv.2109.08238.
- [7] A. Chang, A. Dai, T. Funkhouser, M. Halber, M. Niessner, M. Savva, S. Song, A. Zeng, and Y. Zhang, "Matterport3D: Learning from RGBD Data in Indoor Environments," *International Conference on 3D Vision (3DV)*, Qingdao, China, pp. 667-676, 2017, DOI: 10.1109/3DV.2017.00081.
- [8] P. Anderson, A. X. Chang, D. S. Chaplot, A. Dosovitskiy, S. Gupta, V. Koltun, J. Kosecka, J. Malik, R. Mottaghi, M. Savva, and A. R. Zamir, "On Evaluation of Embodied Navigation Agents," *arXiv:1807.06757*, 2018, DOI: 10.48550/arXiv.1807.06757.
- [9] C. Y. Wang, A. Bochkovskiy, and H. Y. M. Liao, "YOLOv7: Trainable Bag-of-Freebies Sets New State-Of-The-Art for Real-Time Object Detectors," *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, Vancouver, Canada, pp. 7464-7475, 2023, DOI: 10.1109/CVPR52729.2023.00721.
- [10] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, C. Li, J. Yang, H. Su, J. Zhu, et al., "Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection," *arXiv:2303.05499*, 2023, DOI: 10.48550/arXiv.2303.05499.
- [11] C. Zhang, D. Han, Y. Qiao, J. U. Kim, S.-H. Bae, S. Lee, and C. S. Hong, "Faster Segment Anything: Towards Lightweight SAM for Mobile Applications," *arXiv:2306.14289*, 2023, DOI: 10.48550/arXiv.2306.14289.
- [12] M. Savva, A. Kadian, O. Maksymets, Y. Zhao, E. Wijmans, B. Jain, J. Straub, J. Liu, V. Koltun, J. Malik, D. Parikh and D. Batra, "Habitat: A Platform for Embodied AI Research," *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, Seoul, Korea, pp. 9339-9347, 2019, DOI: 10.1109/ICCV.2019.00943.
- [13] J. Li, D. Li, S. Savarese, and S. Hoi, "BLIP-2: Bootstrapping Language-Image Pre-Training with Frozen Image Encoders and Large Language Models," *arXiv:2301.12597*, 2023, DOI: 10.48550/arXiv.2301.12597.